



Investigación **Formativa**

MACHINE LEARNING & BASES DE DATOS

Persistencia Híbrida y Analítica Predictiva

Título del proyecto

Infraestructura de Persistencia Híbrida y Despliegue de Modelos de Machine Learning para la Resolución de Problemas de Analítica Predictiva

Objetivo General

Diseñar e implementar una solución analítica e infraestructural integral que combine una arquitectura de persistencia híbrida (SQL Server y MongoDB) para asegurar la gestión, gobernanza e integridad de datos masivos, con el entrenamiento, evaluación y despliegue de modelos de Machine Learning (supervisados y no supervisados) orientados a resolver una problemática real del entorno actual.

1. Selección del Dataset

Cada grupo debe elegir un dataset público de un sector específico que cumpla:

- ☑️ **10,000** Registros.
- 📊 **15** Variables
- 🗉 Problema de Analítica Predictiva claro.



2. Base de Datos en SQL



Normalización

Diseño ER riguroso. Prohibido usar tablas planas (csv-like). Llaves PK/FK definidas.



Gobernanza


Triggers de auditoría, Roles Analítico/Admin y esquemas de Grant/Revoke.



DRP

Plan de recuperación ante desastres. Restauración operativa mediante código SQL.

3. Puente de Datos (ETL)



Workflow en Jupyter Notebook:

-  Conexión via pyodbc o SQLAlchemy.
-  Limpieza de nulos, duplicados y escalamiento.
-  Transformación de variables categóricas.

4. Aprendizaje no Supervisado


Aplicar algoritmos de agrupamiento como K-Means para encontrar patrones ocultos en el dominio y definir el número de grupos óptimo mediante métodos científicos como el Método del Codo o el Coeficiente de Silueta.



Unsupervised Learning

5. Aprendizaje Supervisado

Para el modelado Supervisado (Predicción o Clasificación) definir una variable objetivo. Dividir los datos obligatoriamente en conjuntos de entrenamiento (70-80%) y prueba (20-30%) fijando un estado aleatorio (random_state=42) para garantizar la reproducibilidad. Entrenar y comparar al menos dos modelos diferentes (por ejemplo Regresión Logística vs. Árboles de Decisión, o Regresión Lineal vs. Random Forest).



6. Base de datos mongoDB


Utilizar mongoDB

Por cada modelo entrenado, el sistema debe persistir automáticamente un documento JSON en MongoDB con:

- 🔧 Nombre del algoritmo.
- ⚙️ Hiperparámetros usados.
- 📈 Métricas obtenidas

```
{
  "fecha_experimento": "2026-05-28 14:30:22",
  "tipo_aprendizaje": "No Supervisado",
  "algoritmo": "K-Means",
  "hiperparametros": {
    "n_clusters": 3,
    "init": "k-means++",
    "random_state": 42
  },
  "metricas_obtenidas": {
    "inercia_final": 45231.89,
    "coeficiente_silueta": 0.68
  }
}
```

7. Despliegue en Tiempo Real




Streamlit App

Transformar el backend técnico en una herramienta interactiva:

- Formulario de entrada de datos.
- Inferencia del modelo en vivo.
- Conexión directa a motores DB.

8. Flujo de trabajo resumido



9. Entregables

Componente	Formato	Evidencia
Informe Técnico	PDF	Documentación completa del proyecto
Base de Datos	SQL	Esquema normalizado, Triggers y DRP.
Modelado	Jupyter (.ipynb)	Flujo de Machine Learning y la inyección con mongoDB
Aplicación	Python (.py)	Código de la interfaz interactiva Streamlit.